

# L'analyse des correspondances multiples

$$X(n, p) = \begin{pmatrix} x_1^1 & \dots & \dots & \dots & x_1^p \\ x_i^1 & \dots & x_i^j & \dots & x_i^p \\ x_n^1 & \dots & \dots & \dots & x_n^p \end{pmatrix}$$

➔ Les  $p$  variables sont qualitatives

# Etape 1 – détour : La tableau de contingence

# Principe d'un tableau de contingence

- Il s'agit du tableau résultant de 2 variables qualitatives dans un fichier de données individuel.
- A partir de 2 variables, on peut demander un tableau croisé des effectifs (commande « tab » dans stata). C'est ce qu'on appelle un tableau de contingence.
- Les modalités de la première composent les lignes du tableau.
- Les modalités de la seconde composent les colonnes du tableau

$\mathbf{Y}$ $\mathbf{X}$	$y^1$	$y^2$	$\dots$	$y^j$	$\dots$	$y^J$	Total
$\mathbf{x}^1$	$n_{11}$	$n_{12}$	$\dots$	$n_{1j}$	$\dots$	$n_{1J}$	$n_{1.}$
$\mathbf{x}^2$	$n_{21}$						
$\dots$	$\dots$						
$\mathbf{x}^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
$\dots$							
$\mathbf{x}^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij}$

Y	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
X							
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij}$

## Effectifs conjoints

Viviane LE HAY

Atelier méthodes du Centre Emile Durkheim - 13 mai 2025

Séquence 3/4

ACM

Tri à plat pour X

Y	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
X							
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij}$

Tri à plat pour Y

		Variable 2				
		Modalité 1	Modalité 2	...	Modalité J	Marge 1
Variable 1	Modalité 1	Effectifs conjoints				Effectifs marginaux (tri à plat variable 1)
	Modalité 2					
	...					
	Modalité I					
Marge 2		Effectifs marginaux (tri à plat variable 2)				



# Etape 2 - L'analyse des correspondances (AC) : une méthode d'analyse d'un tableau de contingence

Y X	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij} = n$

→ L'AC analyse un tel tableau et répond aux questions suivantes :

- Y a-t-il des lignes du tableau qui se ressemblent ?
- Y a-t-il des lignes du tableau qui s'opposent ?
- Mêmes questions pour les colonnes
  - Y a-t-il des associations de modalités entre X et Y qui s'attirent (effectifs conjoints très élevés) ou qui se repoussent (effectifs conjoints très faibles)

Y X	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij} = n$

→ Si toutes les lignes et toutes les colonnes du tableaux se ressemblent, à quelle situation cela se rapporte-t-il ?

→ Égalité des profils lignes ⇔ Égalité des profils colonnes

$$\Leftrightarrow n_{ij} = \frac{n_{i.} n_{.j}}{n}$$

# Objectifs de l'AC

- Représenter les écarts à l'indépendance des profils lignes et colonnes
- Faire apparaître les modalités de X qui se ressemblent (et donc à l'inverse qui s'opposent)
- Décrire la distribution de X dans les J sous-populations de Y

Y X	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij} = n$

## Fréquences

$$f_{ij} = \frac{n_{ij}}{n} = \frac{\text{Effectif de la cellule}(i, j)}{\text{Effectif total}}$$

Y X	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij} = n$

➔ Ces profils lignes peuvent-  
être appréhendés comme une  
liste de coordonnées dans un  
espace à J dimensions

➔ On peut alors chercher les  
directions de plus grande  
dispersion

## Fréquences lignes (profils lignes)

$$f_{ij} = \frac{n_{ij}}{n_{i.}} = \frac{f_{ij}}{f_{i.}} = \frac{\text{Effectif de la Cellule}(i, j)}{\text{Effectif de la Ligne}(i)}$$

$$f_{.j} = \frac{n_{.j}}{n} = \frac{\text{Effectif de la Colonne}(j)}{\text{Effectif Total}}$$

Y X	y <sup>1</sup>	y <sup>2</sup>	...	y <sup>j</sup>	...	y <sup>J</sup>	Total
x <sup>1</sup>	n <sub>11</sub>	n <sub>12</sub>	...	n <sub>1j</sub>	...	n <sub>1J</sub>	n <sub>1.</sub>
x <sup>2</sup>	n <sub>21</sub>						
...	...						
x <sup>i</sup>	n <sub>i1</sub>			n <sub>ij</sub>			n <sub>i.</sub>
...							
x <sup>I</sup>	n <sub>I1</sub>					n <sub>IJ</sub>	n <sub>I.</sub>
Total	n <sub>.1</sub>			n <sub>.j</sub>		n <sub>.J</sub>	$\sum n_{ij} = n$

→ Ces profils colonnes peuvent-  
être appréhendés comme une  
liste de coordonnées dans un  
espace à I dimensions

→ On peut alors chercher les  
directions de plus grande  
dispersion

## Fréquences colonnes (profils colonnes)

$$f_{c_{ij}} = \frac{n_{ij}}{n_{.j}} = \frac{f_{ij}}{f_{.j}} = \frac{\text{Effectif de la Cellule}(i, j)}{\text{Effectif de la Colonne}(j)}$$

$$f_{i.} = \frac{n_{i.}}{n} = \frac{\text{Effectif de la Ligne}(i)}{\text{Effectif Total}}$$

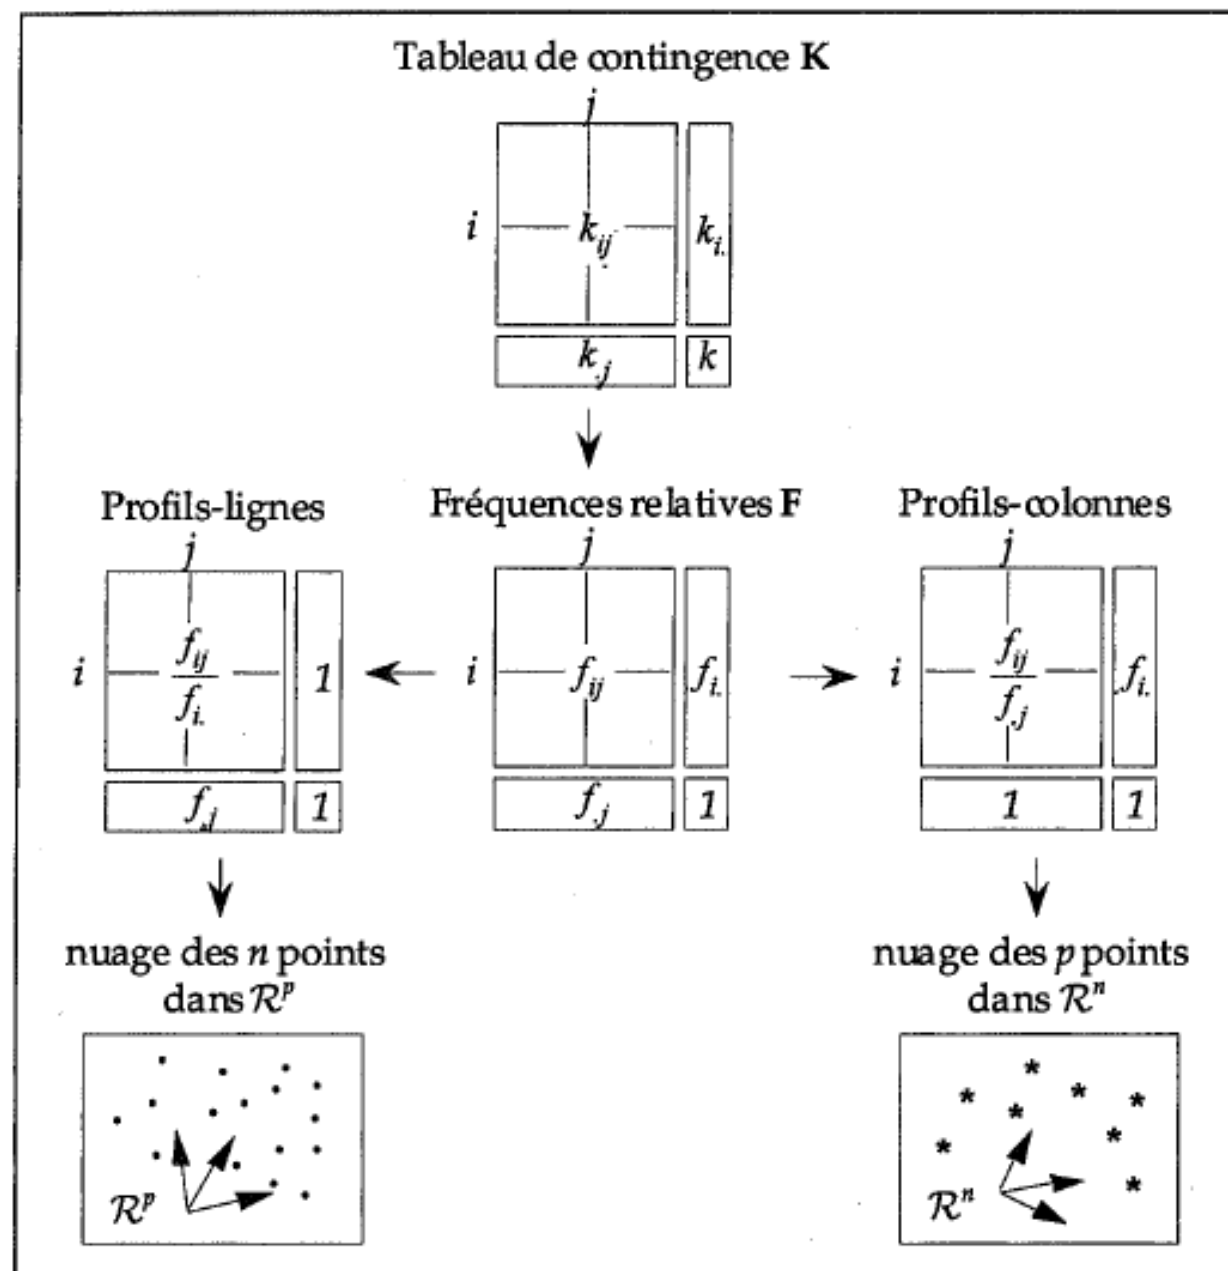


Figure 4.2 – 1. Transformations du tableau de contingence

Source: Lebart,  
Piron, Morineau,  
2006, p. 144



Y X	$y^1$	$y^2$	...	$y^j$	...	$y^J$	Total
$x^1$	$n_{11}$	$n_{12}$	...	$n_{1j}$	...	$n_{1J}$	$n_{1.}$
$x^2$	$n_{21}$						
...	...						
$x^i$	$n_{i1}$			$n_{ij}$			$n_{i.}$
...							
$x^I$	$n_{I1}$					$n_{IJ}$	$n_{I.}$
Total	$n_{.1}$			$n_{.j}$		$n_{.J}$	$\sum n_{ij} = n$

**Distance entre 2 profils lignes**

**= Distance entre 2 individus i et i'**

**= distance du  $\Phi^2$  (distance euclidienne inadaptée)**

$$d_{\Phi^2}^2(L_i, L_{i'}) = \sum_j \frac{(f_{ij} - f_{i'j})^2}{f_{.j}}$$

Y X	y <sup>1</sup>	y <sup>2</sup>	...	y <sup>j</sup>	...	y <sup>J</sup>	Total
x <sup>1</sup>	n <sub>11</sub>	n <sub>12</sub>	...	n <sub>1j</sub>	...	n <sub>1J</sub>	n <sub>1.</sub>
x <sup>2</sup>	n <sub>21</sub>						
...	...						
x <sup>i</sup>	n <sub>i1</sub>			n <sub>ij</sub>			n <sub>i.</sub>
...							
x <sup>I</sup>	n <sub>I1</sub>					n <sub>IJ</sub>	n <sub>I.</sub>
Total	n <sub>.1</sub>			n <sub>.j</sub>		n <sub>.J</sub>	∑n <sub>ij</sub> =n

## Taux de liaison (tableau des taux de liaison soumis à l'analyse)

$$t_{ij} = \frac{f_{ij} - f_{i.}f_{.j}}{f_{i.}f_{.j}} = \frac{\text{Ecart à l'indépendance}}{\text{"Poids Théorique"}} = \frac{n \times n_{ij}}{n_{i.}n_{.j}} - 1$$

# Propriétés de la série des taux de liaison

- Moy  $(t_{ij}) = 0$
- Var  $(t_{ij}) = \Phi^2 = \chi^2 / n$

$$\sum_i \sum_j f_{i.} \times f_{.j} \times t_{ij}^2 = \sum_i \sum_j \frac{(f_{ij} - f_{i.}f_{.j})^2}{f_{i.}f_{.j}} = \sum_i \sum_j \frac{(n_{ij})^2}{n_{i.}n_{.j}} - 1 = \frac{\chi^2}{n}$$

- $\Phi^2 = \text{Somme des valeurs propres} = \sum \lambda_1$

## Nuage des modalités de la variable X

- L'AC réalise une analyse factorielle sur le nuage des modalités de la variable X préalablement centré. C'est la représentation qui restitue avec le plus de fidélité les distance du  $\phi^2$  entre les modalités de X
- Matrice d'inertie, valeurs propres, vecteurs propres, axes et composantes principales
- A chaque modalité on peut associer une coordonnée sur chacun des axes factoriels
- On parle de codage d'une variable qualitative

## Nuage des modalités de la variable Y

- La procédure est identique pour la nuage des modalités de la variable Y

Etape 3 -  
Généraliser la démarche à plus de 2  
variables qualitatives :  
L'analyse des correspondances  
multiples (ACM)

# Du tableau de données au tableau disjonctif complet

## Exemple

# Tableau de données

$R = (n, s)$

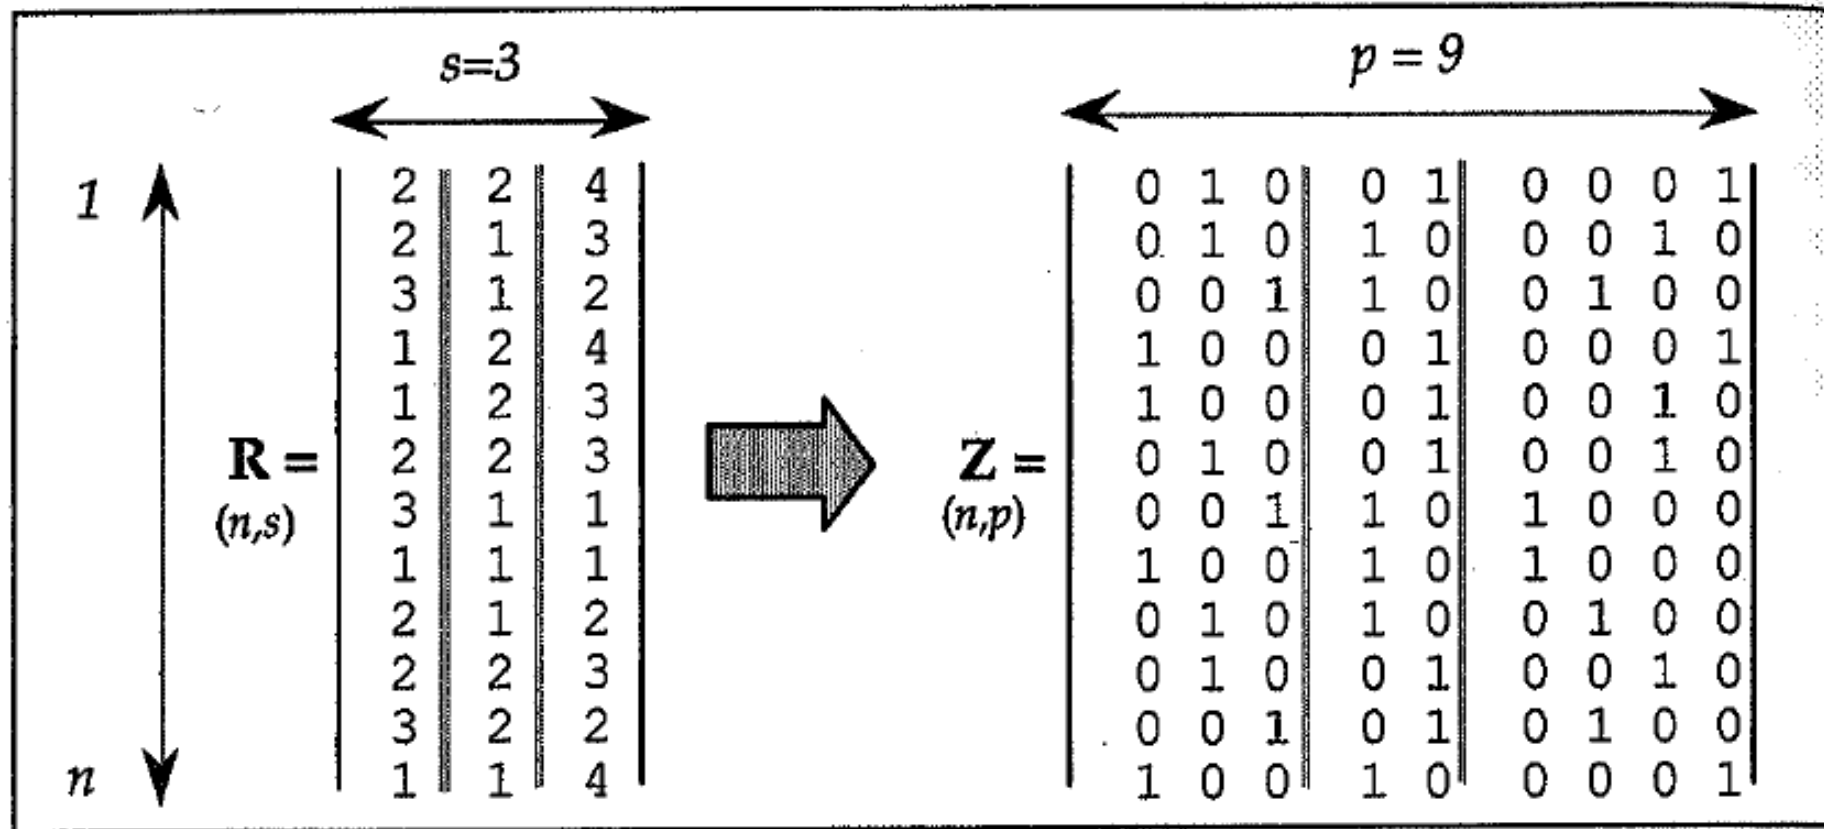
$s=3$

2	2	4
2	1	3
3	1	2
1	2	4
1	2	3
2	2	3
3	1	1
1	1	1
2	1	2
2	2	3
3	2	2
1	1	4

**Figure 5.1 – 1. Tableau de données sous forme de codage condensé**

Source: Lebart, Piron, Morineau, 2006, p. 189

# Tableau disjonctif complet



**Figure 5.1 - .2. Construction du tableau disjonctif complet Z**

Source: Lebart, Piron, Morineau, 2006, p. 190

**Somme des lignes ?** Nombre de questions (Q)

**Somme des colonnes ?** Effectif de la modalité  $k$  ( $n_k$ )

**Somme totale ?**  $nQ$



# ACM : notations fondamentales

- ❑  $I$  : ensemble des  $n$  individus ( $i \in I$ ) (cardinal :  $n$ )
- ❑  $Q$  : ensemble des  $Q$  questions actives ( $q \in Q$ ) (cardinal :  $Q$ )
- ❑  $K$  : ensemble des modalités des questions actives ( $k \in K$ )
- ❑  $K_{\langle q \rangle}$  : sous-ensemble des modalités de réponse de la question  $q$

**ACM** : l'individu  $i$  choisit *une et une seule* modalité de réponse pour chaque question

(Variables catégorisées : chaque variable admet un nombre fini de modalités de réponse)

- si  $q \neq q'$  alors  $\mathbb{K}\langle q \rangle \cap \mathbb{K}\langle q' \rangle = \emptyset$
- $\mathbb{K} = \bigcup_{q \in Q} \mathbb{K}\langle q \rangle$  (ensemble de toutes les modalités de réponse)
- $\mathbb{K}\langle i \rangle$  : patron de réponses de l'individu  $i$
- $\mathbb{I}\langle k \rangle$  : ensemble des individus ayant donné la réponse  $k$  à la question  $q$
- $\mathbb{I} = \bigcup_{k \in K\langle q \rangle} \mathbb{I}\langle k \rangle$
- pour une question  $q$ , si  $k \neq k'$  alors  $\mathbb{I}\langle k \rangle \cap \mathbb{I}\langle k' \rangle = \emptyset$

## Principe géométrique de l'ACM :

- ❑ Construire un nuage euclidien de points représentant les individus
- ❑ Interpréter des axes : déterminer des axes principaux et des variables principales

## Etape fondamentale :

- ❑ Définir les distances entre individus sur la base de leurs réponses aux questions actives

# Le calcul de la distance entre individus dans l'ACM standard

Soit :

- $d_q(i, i')$  la distance entre les individus  $i$  et  $i'$  à la question  $q$
- $n_{\kappa}$  le nombre d'individus ayant choisi le modalité  $\kappa$  à la question  $q$
- $n_{\kappa'}$  le nombre d'individus ayant choisi la modalité  $\kappa'$  à la question  $q$

Propriété fondamentale de l'ACM :

la distance entre deux individus  $i$  et  $i'$  ne dépend que des *questions de désaccord*.

➔ Par conséquent :

si  $q$  est une *question d'accord* entre  $i$  et  $i'$  :  $d_q(i, i') = 0$

## Le calcul de la distance entre individus dans l'ACM standard

Si  $q$  est une question de désaccord entre  $i$  et  $i'$ , l'un ayant choisi la modalité  $k$  et l'autre  $k' (\neq k)$

alors

$$d_q^2(i, i') = \frac{1}{f_k} + \frac{1}{f_{k'}}$$

Avec  $f_k = n_k/n$ , et  $f_{k'} = n_{k'}/n$

La distance globale  $d(i, i')$  entre  $i$  et  $i'$  est définie par :

$$d^2(i, i') = \frac{1}{Q} \sum_{q \in Q} d_q^2(i, i')$$

(moyenne quadratique des distances des questions)

A partir de ces distances, on définit le nuage euclidien des individus.

Le nombre de dimensions sera au plus égal à  $(K-Q)$  (nombre de modalités moins nombre de questions actives) dont on détermine les directions principales.

(on définit les axes principaux en ajustant le nuage par la méthode des moindres carrés orthogonaux)

**Propriété :**

ACM (sur le tableau  $I*Q$ )

= AC du tableau disjonctif complet ( $I*K$ )

L'ACM = AFC sur le tableau disjonctif complet Z, bien que ce tableau ne puisse pas être considéré a priori comme un tableau de contingence (puisque'il est de type : Individus \* Variables )

- ▶ Même transformation des variables
- ▶ Même critère d'ajustement (pondération des points par leurs profils marginaux)
- ▶ Même distance (celle du  $\chi^2$ )

## ► 3 conséquences

- La distance croît avec le nombre de modalité que n'ont pas en commun  $k$  et  $k'$  et ceux d'autant plus qu'il s'agit de modalités rares
- Un individu possédant des modalités rares est éloigné de ceux qui n'ont pas cette modalité
- Deux individus possédant les mêmes modalités pour toutes les variables sont confondus

Les conséquences sont identiques concernant les modalités



Variance du nuage	$V = \frac{K}{Q} - 1$
Nombre de valeurs propres (nb de dim°)(non trivialement nulles)	$L = K - Q$
Moyenne des valeurs propres	$\bar{\lambda} = \frac{V}{K - Q} = \frac{1}{Q}$

Variance totale = somme des valeurs propres

Propriétés des  
coordonnées de  
l'individu  $l$

$$\text{mean } y_l^I = \sum_{i \in I} \frac{y_l^i}{n} = 0$$
$$\text{Var } y_l^I = \sum_{i \in I} \frac{(y_l^i)^2}{n} = \lambda_l$$

Propriétés des  
coordonnées de la  
modalité  $k$  (pour toute  
question  $q$ )

$$\sum_{k \in K} \frac{f_k}{Q} y_l^k = 0$$

Coordonnée du point  
moyen modalité  $k$

$$\sum_{k \in K} \frac{f_k}{Q} (y_l^k)^2 = \lambda_l$$
$$\bar{y}_l^k = \sum_{i \in I_k} \frac{y_l^i}{n_k} = \sqrt{\lambda_l} \times y_l^k$$

## Taux modifiés de Benzécri

Ces taux permettent d'apprécier l'importance relative des axes principaux.

1. On calcule la moyenne des valeurs propres :  $\bar{\lambda} = \frac{1}{Q}$   
(Q = nombre de variables actives de l'analyse)

2. On détermine la valeur-propre « seuil » tel que :  $\lambda_i \geq \bar{\lambda}$   
(Alors  $\lambda_{i+1} < \bar{\lambda}$  )

3. On pose L tel que  $\forall i \leq L, \lambda_i \geq \bar{\lambda}$

4. Pour l'axe i, le taux modifié de Benzécri est égal à  $\tau_i = \frac{(\lambda_i - \bar{\lambda})^2}{\sum_{i=1}^L (\lambda_i - \bar{\lambda})^2}$   
avec  $i \leq L$ .

## Variables supplémentaires

- ▶ Variable continue: calcul du coef de corrélation entre les var. quantitative et les composantes principales du nuages des individus (impossibilité de la représenter graphiquement)
- ▶ Variable qualitative: représentation graphique, relation barycentrique: une modalité supp. est représentée par le point moyen des individus qui prennent cette modalité

# Recommandations

- Travailler avec un nombre de modalités comparable entre les variables actives de l'analyse
- Ne pas travailler avec des modalités aux effectifs trop faibles ( $>5\%$ )

# Retour

## Tableau disjonctif complet

### //

## Tableau de Burt

- Exemple de Saporta

Races de chiens en fonction de différentes caractéristiques

## Données fictives (10 premières lignes)

##	taille	poids	velocite	intellig	affect	agress	fonction
## beauceron	T++	P+	V++	I+	Af+	Ag+	Utilite
## basset	T-	P-	V-	I-	Af-	Ag+	Chasse
## ber_allem	T++	P+	V++	I++	Af+	Ag+	Utilite
## boxer	T+	P+	V+	I+	Af+	Ag+	Compagnie
## bull-dog	T-	P-	V-	I+	Af+	Ag-	Compagnie
## bull-mass	T++	P++	V-	I++	Af-	Ag+	Utilite
## caniche	T-	P-	V+	I++	Af+	Ag-	Compagnie
## chihuahua	T-	P-	V-	I-	Af+	Ag-	Compagnie
## cocker	T+	P-	V-	I+	Af+	Ag+	Compagnie
## colley	T++	P+	V++	I+	Af+	Ag-	Compagnie

# TDC

##	T-	T+	T++	P-	P+	P++	V-	V+	V++	I-	I+	I++	Af-	Af+	Ag-	Ag+
## beauceron	0	0	1	0	1	0	0	0	1	0	1	0	0	1	0	1
## basset	1	0	0	1	0	0	1	0	0	1	0	0	1	0	0	1
## ber_allem	0	0	1	0	1	0	0	0	1	0	0	1	0	1	0	1
## boxer	0	1	0	0	1	0	0	1	0	0	1	0	0	1	0	1
## bull-dog	1	0	0	1	0	0	1	0	0	0	1	0	0	1	1	0
## bull-mass	0	0	1	0	0	1	1	0	0	0	0	1	1	0	0	1
## caniche	1	0	0	1	0	0	0	1	0	0	0	1	0	1	1	0
## chihuahua	1	0	0	1	0	0	1	0	0	1	0	0	0	1	1	0
## cocker	0	1	0	1	0	0	1	0	0	0	1	0	0	1	0	1
## colley	0	0	1	0	1	0	0	0	1	0	1	0	0	1	1	0
## dalmatien	0	1	0	0	1	0	0	1	0	0	1	0	0	1	1	0
## dobermann	0	0	1	0	1	0	0	0	1	0	0	1	1	0	0	1
## dogue_all	0	0	1	0	0	1	0	0	1	1	0	0	1	0	0	1
## epagn_bre	0	1	0	0	1	0	0	1	0	0	0	1	0	1	1	0
## epagn_fra	0	0	1	0	1	0	0	1	0	0	1	0	1	0	1	0
## fox_hound	0	0	1	0	1	0	0	0	1	1	0	0	1	0	0	1
## fox_terri	1	0	0	1	0	0	0	1	0	0	1	0	0	1	0	1
## grand_ble	0	0	1	0	1	0	0	1	0	1	0	0	1	0	0	1
## labrador	0	1	0	0	1	0	0	1	0	0	1	0	0	1	1	0
## levrier	0	0	1	0	1	0	0	0	1	1	0	0	1	0	1	0
## mastiff	0	0	1	0	0	1	1	0	0	1	0	0	1	0	0	1
## pekinois	1	0	0	1	0	0	1	0	0	1	0	0	0	1	1	0
## pointer	0	0	1	0	1	0	0	0	1	0	0	1	1	0	1	0



# Tableau de Burt

##	T-	T+	T++	P-	P+	P++	V-	V+	V++	I-	I+	I++	Af-	Af+	Ag-	Ag+
## T-	7	0	0	7	0	0	5	2	0	3	3	1	1	6	5	2
## T+	0	5	0	1	4	0	1	4	0	0	4	1	0	5	3	2
## T++	0	0	15	0	10	5	4	2	9	5	6	4	12	3	6	9
## P-	7	1	0	8	0	0	6	2	0	3	4	1	1	7	5	3
## P+	0	4	10	0	14	0	0	6	8	3	7	4	7	7	8	6
## P++	0	0	5	0	0	5	4	0	1	2	2	1	5	0	1	4
## V-	5	1	4	6	0	4	10	0	0	4	5	1	5	5	5	5
## V+	2	4	2	2	6	0	0	8	0	1	5	2	2	6	5	3
## V++	0	0	9	0	8	1	0	0	9	3	3	3	6	3	4	5
## I-	3	0	5	3	3	2	4	1	3	8	0	0	6	2	3	5
## I+	3	4	6	4	7	2	5	5	3	0	13	0	4	9	8	5
## I++	1	1	4	1	4	1	1	2	3	0	0	6	3	3	3	3
## Af-	1	0	12	1	7	5	5	2	6	6	4	3	13	0	5	8
## Af+	6	5	3	7	7	0	5	6	3	2	9	3	0	14	9	5
## Ag-	5	3	6	5	8	1	5	5	4	3	8	3	5	9	14	0
## Ag+	2	2	9	3	6	4	5	3	5	5	5	3	8	5	0	13

- On peut réaliser une AC du tableau de Burt (pratique anglo-saxonne), mais dans ce cas on ne peut pas procéder à l'analyse des individus